非结构化数据清洗与分析链路

以豆瓣电影 Top250 为例 | Python · Pandas · 正则表达式 · Matplotlib | 作者：陶惠灵

原始数据 → 质量画像 → 清洗（6 步，每步附断言校验）→ 质量复核 → 业务问题分析（Q1–Q5）→ 结论与局限

250 / 0
部电影 / 清洗中删除的电影

74
个被截断的不完整人名，识别后剔除

6
类数据问题，全部附断言校验

0.31 → 0.11
Pearson 与 Spearman 相关系数对比

一、数据质量画像：清洗前发现的问题

字段	问题	记录数	处理方式
主演	列表页显示不全，末尾以"..."截断	233	按截断位置判断末位名字是否完整，不完整的剔除
导演	末尾以"..."截断	12	同上
主演	缺失	12	保留电影，主演记为空名单，不删行
年份	不是纯 4 位数字，如"1978(中国大陆)"	2	正则提取 4 位年份并转为整数
导演、主演	中英文名混排，多人以"/"分隔	250	正则提取中文名，兼容" · "" · ""-"
类型、国家	一个单元格包含多个值	250	拆分为标签名单，按"含该标签的电影数"统计

二、关键清洗：截断名字的识别规则

截断位置	例子	末位名字是否完整	处理
截在英文名里	张丰毅 Fengyi Zha...	中文名完整	保留"张丰毅"
截在中文名里	凯特·布...、陈...、西恩...	不完整	剔除
截在分隔符或空格后	蒂姆·罗宾斯 Tim Robbins /...	完整	保留

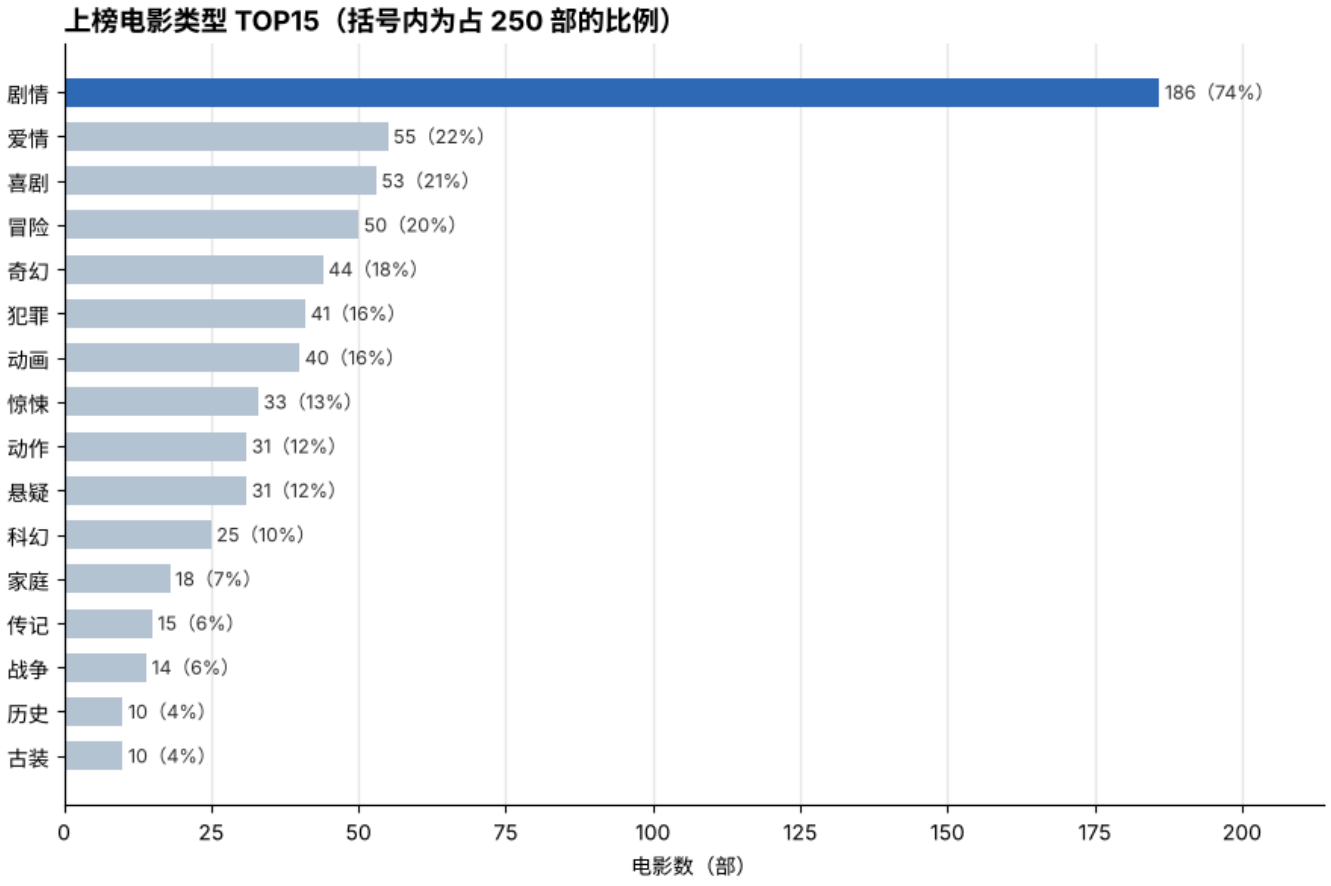
> 不做这一步，"西恩"会被当成一位上榜 3 次的演员；类似的半截名字共 74 个。正则同时允许连字符，避免法语名"让-皮埃尔·热内"被截成"让"。

三、清洗日志

字段	处理	涉及记录数
年份	正则提取 4 位年份并转为整数	2
导演 / 主演	提取中文名、拆分为名单	250
导演 / 主演	剔除被截断的不完整名字	74
主演	缺失保留为空名单（不删行）	12
类型 / 国家	多值字段拆分	250

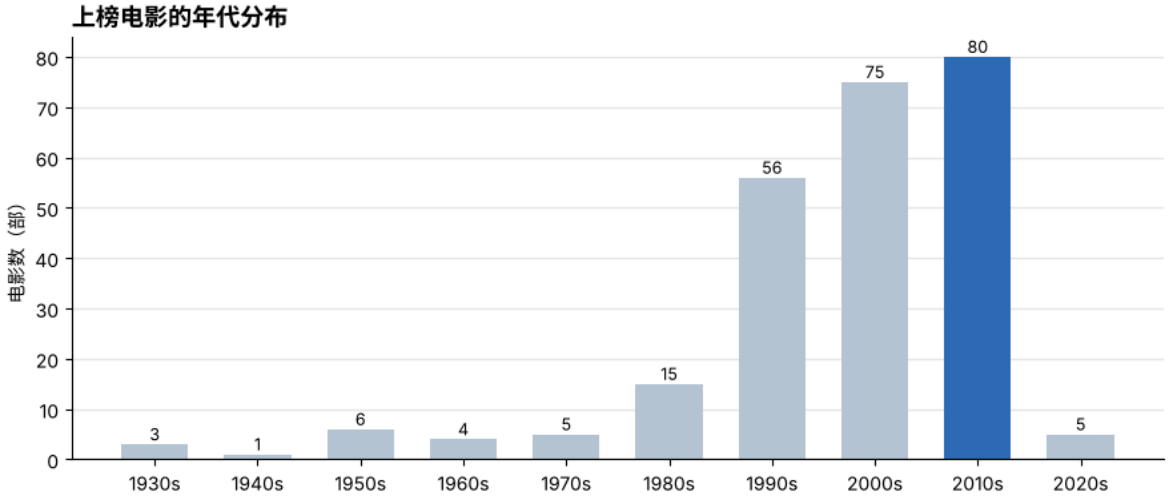
清洗后：250 行，无一删除；进入分析的数据缺失值为 0。评分保留 14 档小数（8.4–9.7），并以断言防止被误转为整数。

Q1 什么类型的电影上榜最多?



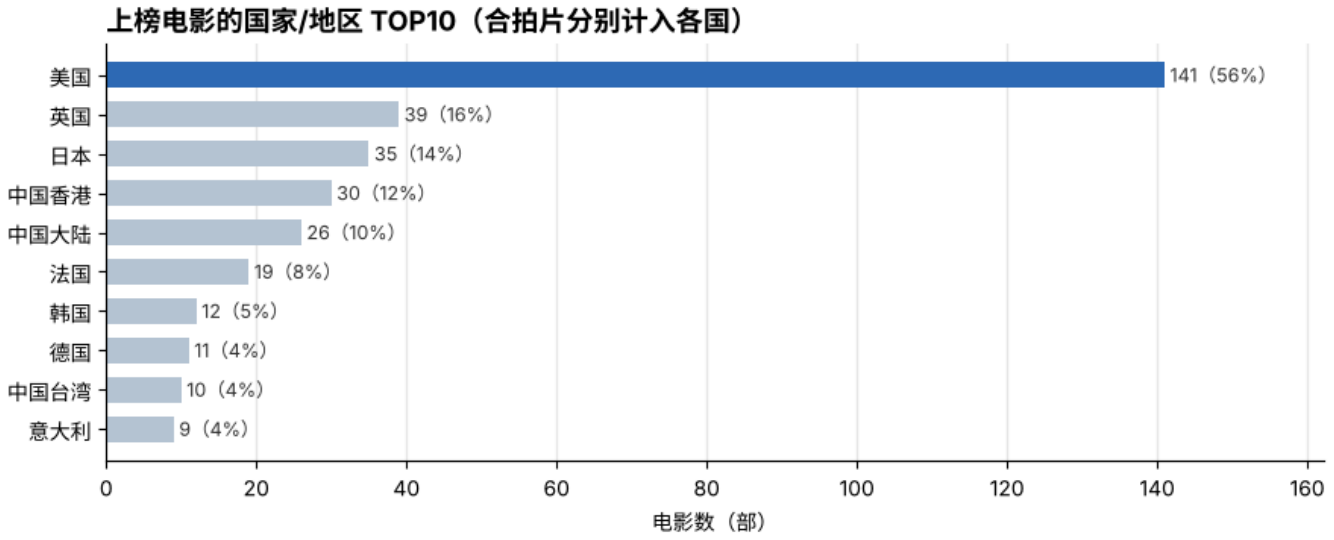
> 共 27 种类型。"剧情"出现在 186 部电影中（74%），是底色标签；第二梯队爱情（55）、喜剧（53）、冒险（50）数量相近。类型是多值标签，各类型数量之和大于 250，所以不用饼图，比例按"含该类型的电影数 ÷ 250"计算。

Q2 上榜电影集中在哪些年代?



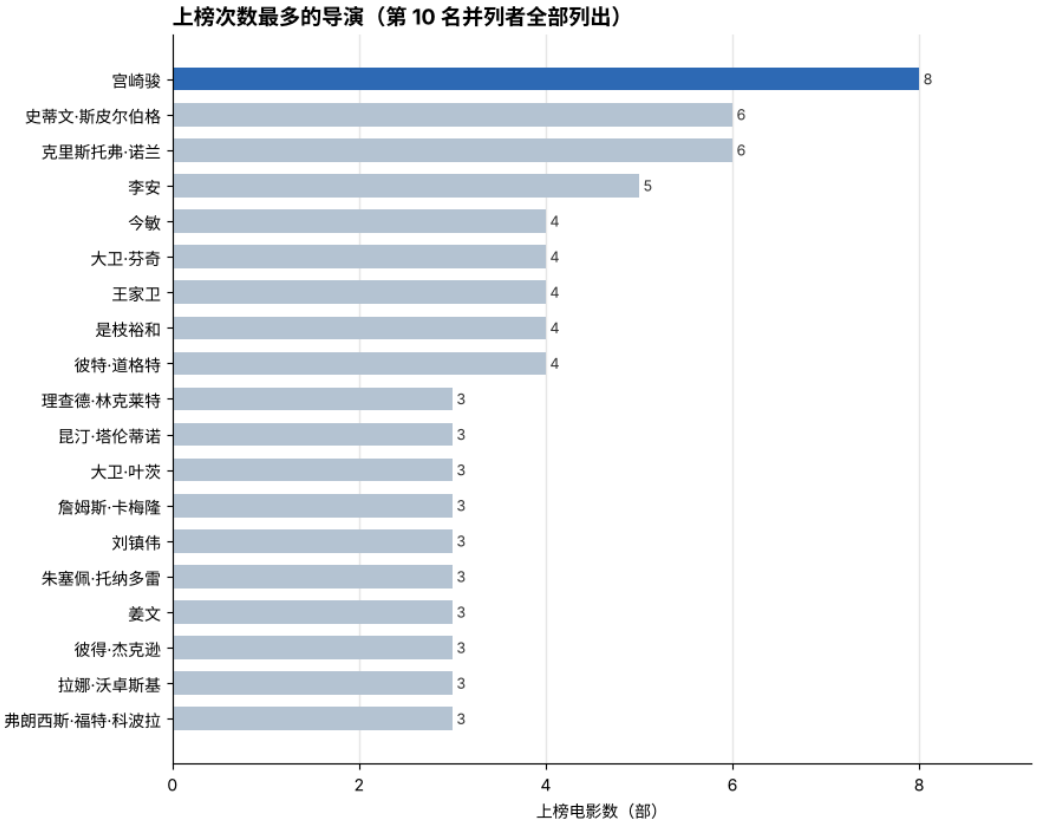
> 2010 年代最多（80 部）；1990–2019 三十年共 211 部，占 84%；最早一部为 1931 年。老片和 2020 年后的新片较少，可能与豆瓣用户结构和新片口碑积累有关，属于榜单的选择偏差。

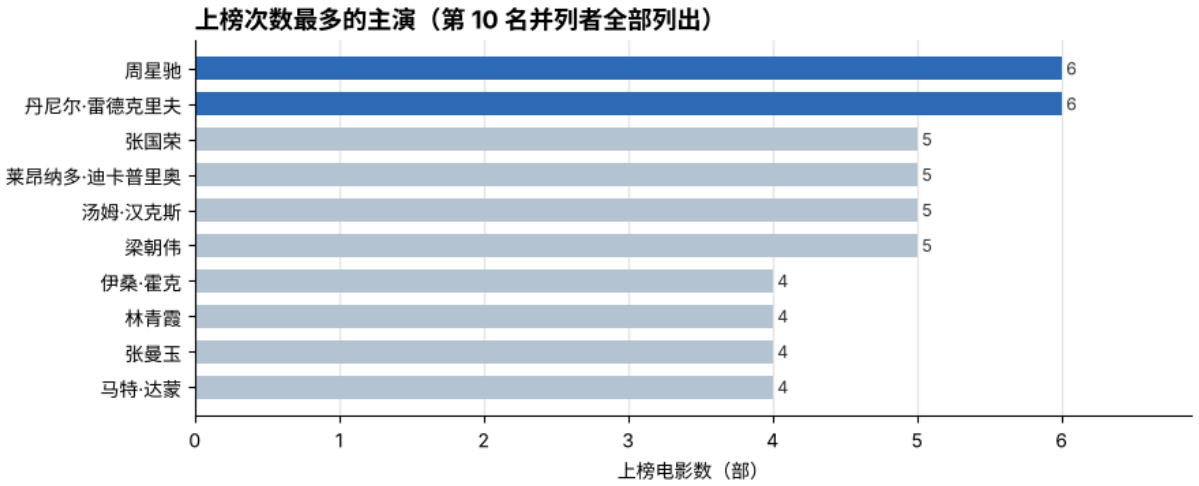
Q3 哪些国家/地区上榜最多?



> 美国参与 141 部（56%），英国 39 部、日本 35 部次之。合拍片共 89 部，分别计入各国，因此各国数量之和大于 250。

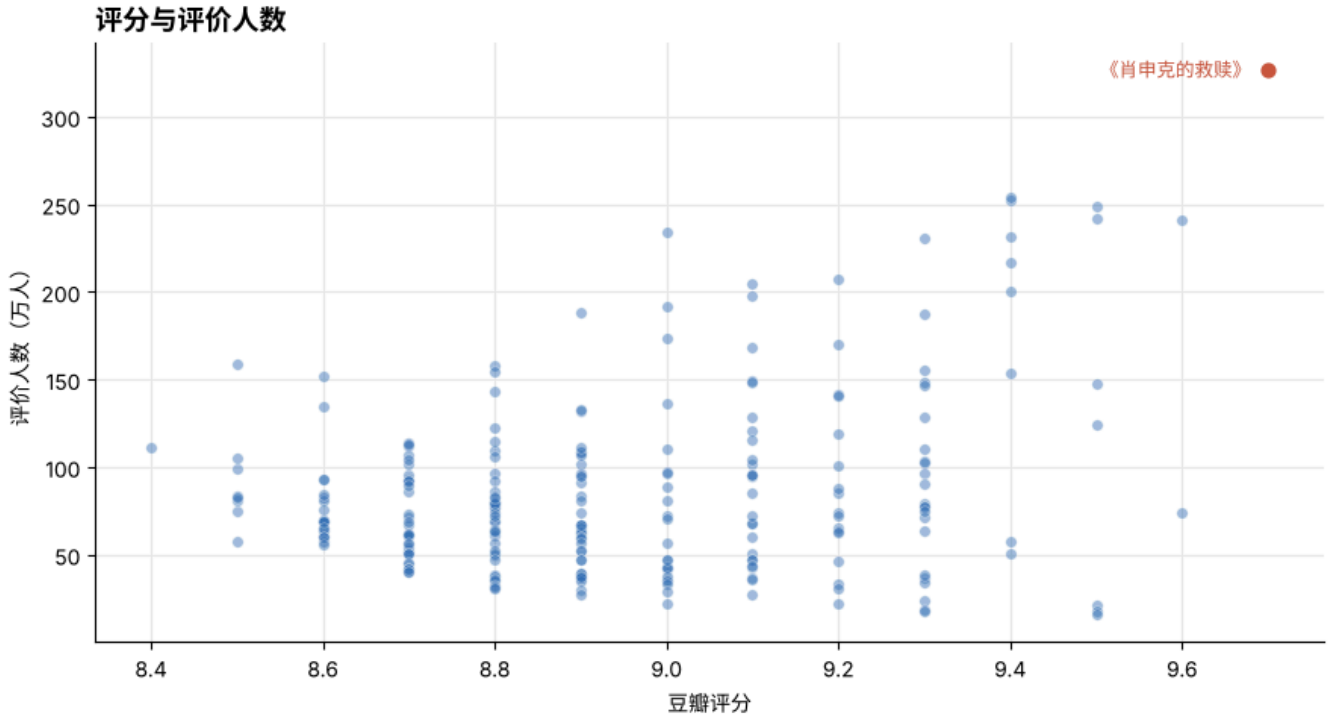
Q4 上榜最多的导演和主演





共 195 位导演、242 位主演。导演第一是宫崎骏（8 部）；主演并列第一为周星驰、丹尼尔·雷德克里夫（各 6 部）。第 10 名有并列时全部列出。主演只统计列表页显示的前几位，是下限值。

Q5 评分高的电影，评价人数也更多吗?



评分档	电影数	评价人数中位数
8.6 及以下	30	75.3 万
8.7–8.9	113	67.1 万
9.0–9.2	66	72.2 万
9.3 及以上	41	102.4 万

Pearson 相关系数 0.31，Spearman 秩相关系数仅 0.11。9.2 分及以下三档的评价人数中位数都在 67–75 万，没有随评分上升；只有 9.3 分以上一档明显更高。结论：Top250 内部评分与评价人数整体关系很弱，0.31 主要由《肖申克的救赎》这类少数极端值拉高。

结论与局限

- **清洗链路**：质量画像 → 清洗 → 断言校验 → 清洗日志，可完整复现；清洗后零删行、零缺失。
- **踩坑复盘**：早期版本把评分误转为整数，14 档评分被压成 2 档，Pearson 系数被低估为 0.24；现已加入类型断言。
- **局限**：人物信息来自列表页，上榜次数为下限值；Top250 只含 8.4 分以上电影，结论只适用于高分电影群体。
- **方法迁移**：名称标准化 ↔ 供应商名称清洗；截断字段识别 ↔ ERP 导出摘要被截断；多值字段 ↔ 一张发票多个费用类别；断言校验 ↔ 月结对账。